01 · 概念 / Bandits / MDP

定位：先看题目指定算法。模型规划 → ③；回报均值 → ④ MC；一步状态值 → ④ TD；Q 表 → ⑤；Bellman 方程 → ②。

1.1 Learning 与概率工具

SL：给定 (x,y) 标签，最小化预测损失。**RL**：与环境交互，无逐步最优动作标签；动作影响未来数据，优化累计回报（延迟奖励/credit assignment）。

$P(A|B)=P(A,B)/P(B)$；$E[X]=\Sigma_x xP(x)$

$Var(X)=E[X^2]-E[X]^2$；$P(A)=\Sigma_b P(A|b)P(b)$

1.2 Bandits / ε-greedy

Bandit 无影响未来的状态转移；若动作改变以后环境，需要 MDP。**Exploit** 选当前估计最好；**explore** 获取信息，牺牲短期换长期收益。

$q_*(a)=E[R|a]$；$a^*\in\text{argmax}_a\ Q(a)$

$Q(a)\leftarrow Q(a)+\alpha[R-Q(a)]$

平稳：奖励分布不变，$\alpha=1/N(a)$ 为样本均值。**非平稳**：固定 α 更重视新样本；旧样本权重按 $(1-\alpha)$ 衰减。计数按动作单独维护。

m 个动作、选定一个贪心动作：$P(a^*)=1-\varepsilon+\varepsilon/m$；其余 ε/m。若 g 个并列贪心且均分利用概率：各为 $(1-\varepsilon)/g+\varepsilon/m$。

例 m=4, ε=.1 ⇒ .925 / .025。随机探索也可选中贪心动作；不能写成 $P(a^*)=1-\varepsilon$。

1.3 MDP / Return

(S,A,T,R,γ)；$T(s,a,s')=P(s'|s,a)$，$\Sigma_{s'}T=1$；$R(s,a,s')$ 为条件期望奖励。$\pi(a|s)$ 为策略。Markov：给定当前状态/动作，无需更早历史。

$G_t=\Sigma_{k=0}^{T-t-1}\gamma^k R_{t+k+1}=R_{t+1}+\gamma G_{t+1}$

T 为终止时刻；G_T=V(terminal)=0。第一个收到的奖励不打折；末项指数 T−t−1。γ=0 只看即时；γ↑ 更看重远期，并可能改变最优策略。

折扣例：立即 1 vs [0,0,10]：$1=10\gamma^2 \Rightarrow \gamma=1/\sqrt{10}\approx.3162$。γ 更大选延迟 10。

02 · 写方程：V / Q / Bellman

$V^\pi(s)=E_\pi[G_t|S_t=s]$；$Q^\pi(s,a)=E_\pi[G_t|s,a]$

$V^\pi(s)=\Sigma_a\pi(a|s)Q^\pi(s,a)$；$V^*(s)=\max_a Q^*(s,a)$

Expectation（固定 π；L13 pp.6–7）：

$$V^\pi(s)=\sum_a \pi(a|s)\sum_{s',r} p(s',r|s,a)[r+\gamma V^\pi(s')]$$

$$Q^\pi(s,a)=\sum_{s',r} p(s',r|s,a)\left[r+\gamma\sum_{a'}\pi(a'|s')\,Q^\pi(s',a')\right]$$

Optimality（最优动作；L13 p.9）：

$$V^*(s)=\max_a\left(\sum_{s',r} p(s',r|s,a)[r+\gamma V^*(s')]\right)$$

$$Q^*(s,a)=\sum_{s',r} p(s',r|s,a)\left[r+\gamma\max_{a'} Q^*(s',a')\right]$$

识别算子：对动作按 π 加权 → Tπ；对动作 max → T*。Qπ 的下一动作按 $\pi(a'|s')$ 求平均；Q* 用 max。随机后果必须先求期望，不能当作可选动作。

03 · 给模型：算 V、找最优 π

已知 T、R；对所有可能后继做 full backup。Prediction 求固定策略价值；control 求最优策略。

3.1 Policy Evaluation → Improvement → Iteration

$V_{k+1}(s)=\Sigma_a\pi(a|s)\Sigma_{s'}T(s,a,s')[R+\gamma V_k(s')]$

确定性 π：动作求和换成 $a=\pi(s)$。同步更新全部读 V_k；in-place 可读本轮新值，数值轨迹不同。

$v^\pi=r^\pi+\gamma P^\pi v^\pi$；$(I-\gamma P^\pi)v^\pi=r^\pi$

解方程例：$v_1=1+.5v_2$，$v_2=2+.5v_1 \Rightarrow v_1=8/3$，$v_2=10/3$。先列每个状态的期望，再联立。

$P\pi(s,s')=\Sigma a\pi(a|s)T(s,a,s')$；$r\pi(s)=\Sigma a,s'\pi(a|s)T(s,a,s')R(s,a,s')$。

$\pi'(s)\in\text{argmax}_a\Sigma_{s'}T(s,a,s')[R+\gamma V^\pi(s')]$

改进定理：若 $Q\pi(s,\pi'(s))\geq V\pi(s)$ 对所有 s 成立，则 $V\pi'\geq V\pi$。一步改进后再继续评估；并列时保留原动作可避免来回切换。

PI：初始化 π → 评估到 Vπ → 对 Vπ 贪心改进 → 重复；策略不变即停。**VI**：每轮直接做最优 backup，不必先评估完一套策略。

3.2 Value Iteration 与策略提取

$$V_{k+1}(s)\leftarrow\max_a\sum_{s'}T(s,a,s')[R(s,a,s')+\gamma V_k(s')]$$

通常 $V_0=0$；第 k 轮对应 k 步最优回报（零末端价值）。只看更新值不够，还要提取动作。

$\pi(s)\in\text{argmax}_a\Sigma_{s'}T(s,a,s')[R+\gamma V(s')]$

argmax 返回动作，max 返回值。策略可能早于价值收敛；V_k 与 V^* 不要混用。

稠密模型运算	时间复杂度
VI 一轮 / 贪心改进	$O(\|S\|^2\|A\|)$
固定/已合并 Pπ 的评估一轮	$O(\|S\|^2)$
直接解评估线性方程	$O(\|S\|^3)$

确定性 PI 每轮：K 次迭代评估 + 一次改进，$O(K|S|^2+|S|^2|A|)$。稀疏转移只算非零分支。

3.3 Convergence / 停止条件

有限 MDP、有界奖励、$0\leq\gamma<1$：Tπ 与 T* 是 γ-contraction，各有唯一不动点。

$\|Tu-Tv\|_\infty\leq\gamma\|u-v\|_\infty$

$\|V_k-V^*\|_\infty\leq\gamma^k\|V_0-V^*\|_\infty$

残差 $d=\|TV-V\|_\infty \Rightarrow \|V-V^*\|_\infty\leq d/(1-\gamma)$

γ=1 不能直接套压缩结论；有终止态也不保证必然终止。正奖励循环可能使回报无穷。

3.4 Hand calculation / 原课件模型

赛车 C=Cool, W=Warm, O=terminal；令 $c=V_k(C)$，$w=V_k(W)$，$V(O)=0$：

$V_{k+1}(C)=\max\{1+\gamma c,\ 2+\gamma(c+w)/2\}$

$V_{k+1}(W)=\max\{1+\gamma c,\ -10\}$

从 (0,0) 起，γ=1：(2,1) → (3.5,2.5)。γ=.5 时最优 (C:Fast,W:Slow)，V*=(3.6,2.8)。

4×4 GridWorld：两对角角落终止；随机四方向，非终止每步 −1，越界留原格。$V_0=0 \Rightarrow$ 第一轮非终止全 −1，终止 0；第二轮邻终止格 −1.75，其余 −2（γ=1）。

噪声 backup：0.8 向目标、两侧各 .1；γ=.9，后继旧值 (1,0,0)，即时奖励 0 ⇒ q=.8×.9=.72。多个分支到同一格要累加概率。

04 · 给轨迹：MC / TD 怎么算

方法	模型	采样	自举
DP	需要	否	是
MC	不需要	是	否
TD	不需要	是	是

Sampling 用实际经验代替模型期望；**bootstrapping** 用当前价值估计构造目标。

4.1 Monte Carlo / 完整回合

$V(s)\leftarrow V(s)+\alpha[G_t-V(s)]$

固定策略 π 产生完整 episode。First-visit：每回合每状态只用**时间上第一次**访问的 G；Every-visit：每次访问的 G 都用。跨回合继续累计。

$N(s)\leftarrow N(s)+1$；$V(s)\leftarrow V(s)+(G-V(s))/N(s)$

先倒序算 $G\leftarrow r+\gamma G$，再按时间正序判断首次访问；倒序遇到的第一次是原轨迹最后一次，不能混淆。

例：同一 s 在 t=1,2 出现，$R_2=2, R_3=4$，t=3 终止，γ=1 ⇒ $G_1=6, G_2=4$；本回合 first=6，every=(6+4)/2=5。

MC control：估计 Q(s,a)，再 ε-greedy 改进；直接由 V 选动作通常仍需模型。Exploring Starts 随机初始(s,a)保证覆盖；现实中不一定可实现。

4.2 TD(0) / 一步经验

$y_t=R_{t+1}+\gamma V(S_{t+1})$；$\delta_t=y_t-V(S_t)$

$$V(S_t)\leftarrow V(S_t)+\alpha[R_{t+1}+\gamma V(S_{t+1})-V(S_t)]$$

每次转移即可更新，不必等 episode 结束。目标是“奖励 + 后继估计”；只更新出发状态 S_t。

终止时 y=r，没有后继自举。δ>0 上调；δ<0 下调。α 是更新幅度，γ 是未来奖励权重。

Lake：V 初值 0，α=.1, γ=.5，每步 r=−.4；A→B→C→B：V(A)=−.04，V(B)=−.04，V(C)=.1[−.4+.5(−.04)]=−.042。第三步使用已更新的 V(B)。

4.3 MC vs TD: bias / variance

MC target：固定策略的完整回报是无偏样本；通常方差高，对初值较不敏感；必须等回合结束。**TD target**：依赖尚不准确的 V，通常有偏、较低方差；可在线、适合持续任务，初值影响更大。

TD target 有偏 ≠ TD 必不收敛。表格 TD(0) 在固定策略、充分访问、适当步长等条件下可收敛到 Vπ；任意函数近似不保证。

4.4 n-step return / 多步 TD

若 $t+n<T$：$G_{t:t+n}=\Sigma_{k=0}^{n-1}\gamma^k R_{t+k+1}+\gamma^n V(S_{t+n})$

若 $t+n\geq T$：$G_{t:t+n}=\Sigma_{k=0}^{T-t-1}\gamma^k R_{t+k+1}$

$V(S_t)\leftarrow V(S_t)+\alpha[G_{t:t+n}-V(S_t)]$

n=1 → TD(0)；看到终点 → MC 回报。n 步更新延迟到收到相应奖励，回合结束还要补齐尾部更新。

特别注意 t+n=T 也无自举项；n 个奖励的幂为 $0,\ldots,n-1$，后继 V 的幂才是 n。

例 $R_{+1}=1, R_{+2}=2, \gamma=.5$ 两步后未终止且 V=4 ⇒ y=1+.5×2+.25×4=3；两步后终止 ⇒ y=2。

n-step SARSA：未终止公式末项替换为 $\gamma^n Q(S_{t+n},A_{t+n})$，使用实际后续动作；到终点同样删掉自举项。

05 · 给 Q 表：SARSA / Q-learning

$Q(s,a)\leftarrow Q(s,a)+\alpha[y-Q(s,a)]$

$=(1-\alpha)Q(s,a)+\alpha y$

5.1 两种目标，区分数据与学习目标

记号：$r=R_{t+1}$，$s'=S_{t+1}$，$a'=A_{t+1}$。

SARSA：$y=r+\gamma Q(s',a')$，$a'\sim\pi(\cdot|s')$

Q-learning：$y=r+\gamma\max_b Q(s',b)$

On-policy：behavior=target；SARSA 学实际行为策略（含探索）的价值。**Off-policy**：behavior 可不同于 target；Q-learning 用探索收集数据，但目标为下一步贪心值。

SARSA 会计入探索带来的风险；Q-learning 的 greedy target 不要求实际采取贪心动作。两者都需要探索，off-policy 不等于不需要数据覆盖。

5.2 实现顺序 / terminal

SARSA：选 A → 执行得到 r,S′ → 若未终止，按当前策略先选 A′ → 更新 Q(S,A) → S←S′,A←A′（执行刚才选的 A′）。

Q-learning：行为策略选 A → 得到 r,S′ → 用 max_b Q(S′,b) 更新 → 继续按行为策略选动作。无需等待实际下一动作才能计算目标。

真正终止：两者 y=r；不再选 A′、不取 max。更新只改当前 (s,a)，不是整行 Q 表。一般的外部时间截断不自动等同于终止。

对照题 Q(s,a)=2,r=0,γ=.9,α=.1；实际下一动作值 1，最大值 5：SARSA y=.9，δ=−1.1，Q′=1.89；Q-learning y=4.5，δ=2.5，Q′=2.25。

小狗 Q 表：全 0，α=.1,γ=.99；先向右得 +1 ⇒ Q((0,0),→)=.1；再向下得 −10 并终止 ⇒ Q((0,1),↓)=−1。其余项保持 0。

5.3 Convergence / GLIE

有限表格、适当折扣/回合终止条件、有界奖励下：每个 (s,a) 充分访问；步长按该对的更新次数 n 满足：

$\Sigma_{n=1}^{\infty}\alpha_n(s,a)=\infty$；$\Sigma_{n=1}^{\infty}\alpha_n(s,a)^2<\infty$

典型 $\alpha_n=1/n$。第一条防止停止学习过早，第二条控制噪声。固定 α 适合跟踪漂移，但一般不能保证精确收敛。

Q-learning：以上条件下收敛 Q*；行为可持续探索。

SARSA → Q*：还需 **GLIE**（Greedy in the Limit with Infinite Exploration）：无限访问，且行为策略极限趋于贪心。

ε→0 只保证逐渐贪心，**不自动保证充分访问**；固定 ε>0 不是 GLIE。α 控制更新，ε 控制探索，勿混淆。

06 · 特征表示 / 做题防错

Tabular：每个(s,a)独立存值，约 $|S||A|$ 参数；没访问的状态不自动获得经验。**Features**：φ(s,a) 描述距离、方向、风险等；共享参数在相似局面间泛化。

线性例：$Q(s,a;w)=w^T\varphi(s,a)$

$\varphi=(1,2)$, $w=(.5,-1) \Rightarrow Q=-1.5$。神经网络 $Q(s,a;\theta)$ 可学非线性特征；表格收敛结论不能直接照搬。

手算顺序：①辨 prediction/control 与方法；②列 (s,a,r,s′[,a′])；③固定旧值；④算 target y；⑤ δ=y−旧值；⑥旧值 +αδ；⑦最后选动作。

易错速查：期望≠单次样本；reward≠return；V≠Q；max≠argmax；π 权重与转移概率都要乘；同步≠在线；终止奖励只算一次；折扣指数从 0 起。